

DOI:10.13196/j.cims.2023.0731

基于元特征增强的小样本 PCB 缺陷检测

宋涛^{*}, 李程, 熊海龙, 叶定兴, 袁川, 赵月雯, 唐宏耀, 冉璐
(重庆理工大学 光纤传感与光电检测重庆市重点实验室, 重庆 400054)

摘要: 面向小样本条件下印刷电路板 (printed circuit board, PCB) 表面缺陷检测任务, 引入元学习方案, 充分提取先验知识并在新缺陷上进行快速泛化。同时, 设计了一种基于元特征增强的小样本检测算法。首先, 将元学习与微调策略相结合, 元测试阶段仅微调检测器头部, 改善知识迁移过程中的分类模糊。然后, 针对 PCB 新类与基类缺陷易于混淆的问题, 在支持分支设计全局特征融合模块, 将全局通道特征与原始支持特征融合以区分不同缺陷类别。最后, 在查询分支上引入自注意力模块提升网络对小目标的关注度, 帮助解决缺陷目标漏检问题。本文所提的方法在 10shot 任务中展现出优异的检测性能, 在 PKU-Market-PCB 缺陷数据集的新类 AP (Average Precision, AP) 达到了 62.4%。

关键词: 小样本目标检测; 元学习; 特征增强; PCB 缺陷检测

中图分类号: TP391; TP18

文献标识码: A

Few-shot PCB defect detection based on meta-feature enhancement

SONG Tao⁺, LI Cheng, XIONG Hailong, YE Dingxing, YUAN Chuan, ZHAO Yuwen, TANG Hongyao,
RAN Lu

(Chongqing Key Laboratory of Optical Fiber Sensing and Photoelectric Detection, Chongqing
University of Technology, Chongqing 400054, China)

Abstract: A meta-learning approach is introduced for the task of PCB surface defect detection under few-shot conditions, aiming to extract prior knowledge and achieve rapid generalization on novel defects. Simultaneously, a few-shot detection algorithm based on meta-feature enhancement is designed. Firstly, meta-learning is combined with fine-tuning strategy, where only the detector head is fine-tuned during the meta-testing phase, improving the classification ambiguity in the knowledge transfer process. To address the issue of confusion between novel and base class defects on PCB, a global feature fusion module is designed in the support branch to fuse global channel features with original support features, distinguishing different defect categories. Finally, a self-attention module is introduced in the query branch to enhance the network's focus on small targets, helping to solve the problem of defect target omission. The method proposed in this paper demonstrates excellent detection performance in the 10-shot task, achieving a novel class Average Precision (AP) of 62.4% on the PKU-Market-PCB defect dataset.

Key words: few-shot object detection ; meta-learning; feature enhancement; PCB defect detection

收稿日期: 2023-12-04; 修订日期: 2024-03-18。Received 04 Dec. 2023; accepted 18 Mar. 2024.

基金项目: 重庆市科技局基础与前沿研究计划资助项目 (cstc2021jcyj-msxmX0348); 中国博士后科学基金资助项目

(2022M710543); 重庆理工大学科研创新团队资助项目 (2023TDZ014)。**Foundation items:** Project supported by the Basic and Frontier Research Program of Chongqing Science and Technology Bureau, China (No. cstc2021jcyj-msxmX0348), the Postdoctoral Science Foundation, China (No. 2022M710543), and the Research and Innovation team project of Chongqing University of Technology, China (No. 2023TDZ014).

1 引言

印刷电路板（PCB）是设备中连接各种电子元件的重要组成部分，它提供了电路连接和硬件支持的功能，对于设备的稳定和可靠运行至关重要^[1]。随着集成电路封装技术的迅速进步，印刷电路板上的布线变得越来越密集，即使是微小的表面缺陷也可能导致电路连接失效，并缩短电路板的使用寿命^[2]。基于卷积神经网络（CNN）的检测算法通过训练大量数据来获得图像中特定目标的语义类型和位置信息，被广泛用于 PCB 表面缺陷检测。Luo 等^[3]在 Faster-rcnn 基础上提出了解耦两阶段 PCB 缺陷检测框架，通过两个专用模块有效定位和分类非显著缺陷。Liao 等^[4]在 YOLOv5 的基础上引入 Squeeze and Excitation-SiLU（SE-SiLU）注意力模块，使网络更加关注浅层特征的微小缺陷信息。Lin 等^[5]设计了边缘和多尺度反向注意力网络（EMRA-Net），通过尺度模块和两个专门提取微小和低对比度缺陷的新模块融合局部和全局特征。当前的 PCB 缺陷检测算法往往需要大量样本进行训练。然而，在工业场景中，由于产品故障率的把控，构建一个包含大量数据的缺陷样本库面临诸多困难。与 VOC 或者 COCO 这种自然场景数据集相比，缺陷数据集提供的样本数量太少^[6]。一方面，PCB 图像中有部分种类缺陷较多，而少部分类别缺陷只有几十张甚至几张样本，即面临着样本类别不均衡的问题。另一方面，在实际生产过程中，PCB 表面难免会出现新的缺陷，这些缺陷样本通常也很稀少。如果直接使用深度学习目标检测算法可能会导致模型过拟合，无法适用于新的缺陷场景。为了缓解上述问题，少样本目标检测算法采用先验知识泛化的思想使用很少的训练样本就能够得到想要的结果。

从先验知识获取的方式来看，少样本目标检测可分为基于微调、度量学习、数据增强和元学习等几种范式^[7,8]。微调策略将源域学习到的知识迁移到目标域上，以此来提升目标任务在小样本条件下的检测性能。TFA^[9]提出了一种基于迁移学习的方法，在新类上将检测器头部之前的所有网络冻结，只对最后一层进行微调，这种简单的训练方式带来了显著的精度改进。度量学习通常将不同样本嵌入到相同空间，通过计算距离或者相似度对其进行区分。Sun 等^[10]在检测器头部加入新的对比分支，利用余弦相似性函数度量感兴趣区域（ROI）特征和特定类别向量的相似程度。数据增强通过直接增加训练的图像数量或者间接对特征进行增强。Wu 等^[11]提出了一种多尺度正样本优化方法，通过构建目标金字塔，生成多尺度正样本，解决目标尺度稀疏分布问题。而元学习通过在多个小样本任务上进行训练，使模型更好地利用先前任务中的经验知识在新场景中进行泛化。Meta R-CNN^[12]专注于每个 RoI 特征，引入了一个预测头重塑网络（PRN）以推断其类注意力向量并将加权后的注意力特征输入到检测头中完成检测任务。Zhang 等^[13]提出 Meta-DETR 元学习框架，使用编码解码器来替代原有的非极大值抑制等后处理操作，在图像层面上实现目标分类与定位。

在上述小样本目标检测方法中，微调方法操作简单，效果明显，但是对源域和目标域数据之间的相关性要求比较高^[8]。度量学习多用于区分不同类别，在定位上较依赖区域建议网络，适用于定位精度要求不高的情况。单独使用数据增强对模型的性能提升有限，难以从根本上解决样本数量不足的问题。元学习则通过在大量小样本任务中习得良好的初始化参数，在新任务中只需少量的迭代即可获得较好的性能。面向小样本新场景下的

PCB 表面缺陷检测任务，将元学习和微调策略相结合，是一个值得探索的方向。

目前基于元学习的目标检测方法主要适用于自然场景图像。然而，对于 PCB 图像而言，存在着独特的挑战。首先，PCB 上的缺陷通常非常微小，其尺寸仅为毫米级，网络进行特征提取时，不可避免地会损失图像信息进而造成漏检。此外，PCB 包含多个缺陷类别，由于原始缺陷与新缺陷在样本数量上的严重不平衡，在微调过程中模型在分类上更加偏向于样本数较多的基类^[9,14]。同时，不同缺陷类别具有的相似性使得新类与基类之间的区分变得更加困难。例如，在所有缺陷类别中，新类“鼠咬”与基类“毛刺”和“短路”之间具有更高的相似性，在数据量有限的情况下，更容易导致模型将不同种类缺陷误检^[1]。

基于上述观察结果的启示，从元特征增强的角度出发设计小样本 PCB 缺陷检测算法。首先，为帮助元学习模型正确分类，提出了全局特征融合模块，将全局通道特征与原始支持特征相叠加，帮助改善支持分支的类别样板效果。同时，将元学习与微调策略相结合，元训练阶段更新整个模型参数，元测试阶段冻结部分参数，仅微调检测器头部，避免元知识迁移过程中的分类混淆。另外，在查询分支上引入自注意力模块，它能够捕获全局上下文信息，并学习到不同层次的特征表示，更好地对小目标缺陷进行关注，以此来提高查询分支表征能力。最后，通过卷积的方式将增强后的查询与支持特征进行聚合送入到检测器头部进行定位与分类。

2 基于元特征增强模型结构

首先在 2.1 节中介绍本文提出方法的总体框架，然后在 2.2 节介绍基线模型改进思路，最后在 2.3 、2.4 节中详细阐述元特征增强模块的组成结构。

2.1 模型架构

本文基于 Meta R-CNN^[12] 的算法设计一种新的小样本检测方法，并参照微调策略设计基线元学习网络。该模型的总体结构如图 1 所示。首先，将支持图像和查询图像分别输入到相应的特征提取网络中，通过全局特征融合模块对提取到的支持特征进行处理，以生成不同类别的样板。同时，利用自注意力模块对原始查询特征进行增强。最后，对查询与支持特征进行点积操作，将聚合之后的元特征输入到检测器头部进行分类和检测框回归。图中， F_q 、 F_s 分别表示原始查询与支持特征， $F_{q'}$ 、 $F_{s'}$ 则表示增强后的查询支持特征。

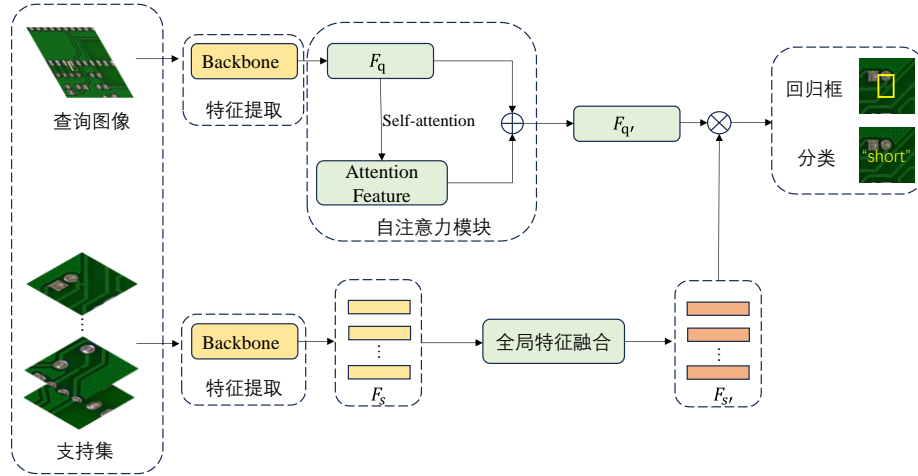


图1 元学习 PCB 缺陷检测方案

在骨干网络选取上,对多个卷积神经网络进行了性能比较,包括 VGGNet^[15]、MobileNetV2^[16]、ResNet-101^[17]等,并在 PCB 缺陷数据集上进行训练和测试。在参数规模或计算复杂度近似的条件下, ResNet-101 具有更深的网络结构,提供了更强的特征提取能力,适用于数据集小、精度要求高的 PCB 缺陷检测任务。其基本结构单元为基于卷积的残差块,残差块结构如图 2 所示:首先,输入特征经过第一个卷积层和激活函数后得到 $F(x)$,然后 $F(x)$ 再经过权重层与输入 x 相加之后得到 $H(x) = F(x) + x$,最后经过 Relu 函数激活后传递给下一层网络。传统卷积神经网络随着深度增加,梯度信息会逐渐消失,导致训练困难,因为每一层的特征变换会涉及到多个非线性操作。而残差结构通过引入跳跃连接和残差连接,将输入特征层直接传递到后续层。这样,即使后续操作对特征进行了变换,输入特征 x 也能够直接从前向传递到后面的 $H(x)$ 层,避免了梯度消失的问题,从而保证网络充分学习特征的同时性能不会下降。




图2 残差结构示意图

2.2 基线元学习网络

Faster R-CNN^[18]是一种流行的二阶段目标检测算法,模型组件主要包括主干网、区域提议网络(RPN), Bbox 检测头,检测头由分类器和回归器组成,分类器对对象类别进行分类,回归器用于预测边界框坐标的回归。Meta R-CNN 将元学习与 Faster R-CNN 中 RPN 提取的 RoI 特征结合,解决了元学习难以处理单图多实例的问题。

在元训练阶段, Meta R-CNN 首先使用骨干网络提取基类元特征,然后将其共享给查询和支持分支,支持

和查询分支分别通过 RPN 网络生成不同类别的 ROI 特征 F_s 和 F_q ， F_s 和 F_q 进行特征聚合并将聚合 ROI 特征输入到检测器头部中完成检测任务。在元测试阶段，Meta R-CNN 利用基类和新类的平衡样本进行微调。如图 3 所示：Meta R-CNN 微调整个网络，目的是将元训练过程中学习到的基类知识进行迁移，实现新类别的检测。然而，在 Faster R-CNN 中，RPN 主要用于提取 ROI 特征，功能上是类不可知的，具体的分类由 Bbox 检测头部来完成。如果直接进行整个网络的参数更新可能会造成基类向新类的知识迁移过程中的分类混乱，从而损害新类别的检测精度。

本方案将特征表示学习和 Bbox 分类预测学习分为两步，第一步与 Meta R-CNN 相同，在数据丰富的基类样本上进行元训练，充分提取基类元特征。第二步元测试阶段则在小规模的平衡数据集上仅微调检测器的最后一层，完成 Bbox 分类预测。如图 4 所示：在元测试阶段冻结了大部分参数，只微调了检测器的头部，无需进一步的参数更新，从基类学习到的特征会转移到新类。同时，为方便下一步引入指定模块，将查询和支持分支进行特征解耦。

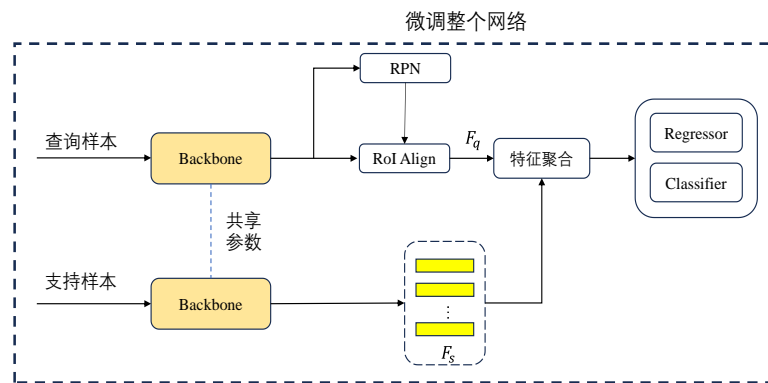


图 3 Meta R-CNN 模型示意图

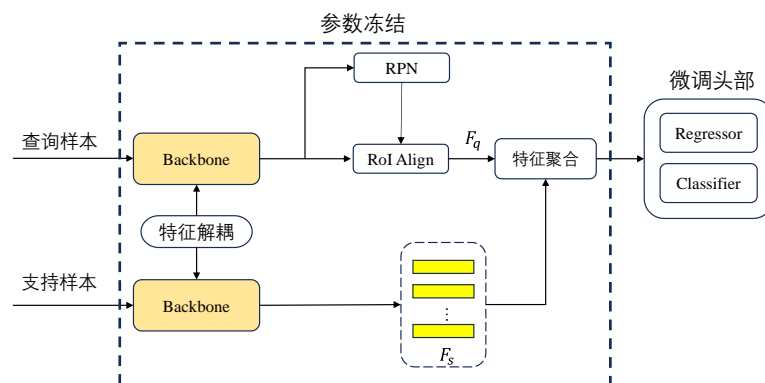


图 4 基线网络模型示意图

2.3 查询自注意力模块

PCB 原始图像的像素一般在 2000-3000 之间，但待检测的缺陷目标通常只包含几个像素值，如果直接使用骨干网络提取到的特征进行检测，将会导致模型无法充分提取目标特征从而缺乏对目标的判别能力。为了解决上述问题，在查询分支中引入自注意力模块进行特征增强。自注意力^[19]具有以下优势：首先，不需要依赖上

下文信息，它能够专注于目标自身的特征，避免其他目标的干扰；其次，通过计算任意两个位置之间的注意力权重，建立目标与周围像素的联系，提高表征能力。

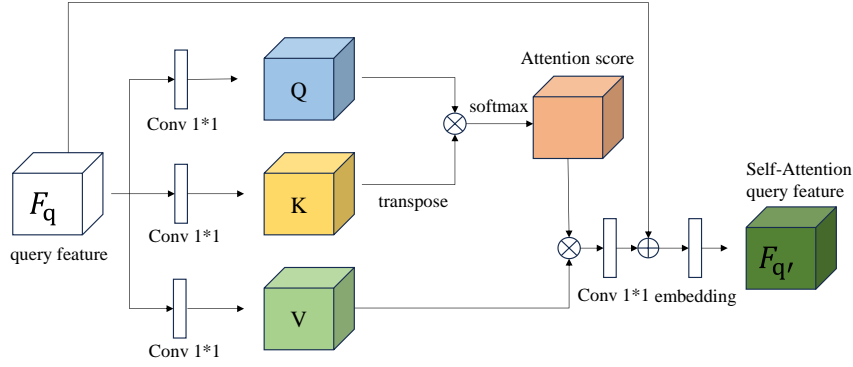


图 5 自注意力示意图

自注意力结构如图 5 所示：首先对输入的特征图在通道维度上进行 1×1 卷积操作，得到 Query、Key 和 Value 权重向量。然后，通过将 Query 向量与 Key 向量进行点积操作，计算得到注意力得分，使用 Softmax 层对得分进行归一化处理。将 Value 矩阵与注意力权重相乘得到最终的自注意力特征图输出。最后，将骨干网络提取到的查询特征 F_q 与自注意力特征 $A(Q, K, V)$ 进行相加得到最终的增强特征。计算过程如下所示：

$$A(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (1)$$

$$F_{q'} = A(Q, K, V) \oplus F_q \quad (2)$$

式中： Q, K, V 分别代表 Query、Key 和 Value 向量， K^T 表示 Key 向量的转置， $\sqrt{d_k}$ 表示 Query 向量维度，除以 $\sqrt{d_k}$ 可以防止经过 Softmax 操作后产生非常小的梯度，保证训练的稳定性， \oplus 表示矩阵加法。

2.4 全局特征融合模块

PCB 图像上缺陷类间的区分是一个具有挑战性的任务。在元学习网络中，查询分支提取到的图像特征需要与支持特征加权聚合从而区分出 PCB 缺陷所属的类别，因此支持特征具有类别样板的作用。为了提高支持特征的质量，准确区分不同类别，在此设计全局特征融合模块。

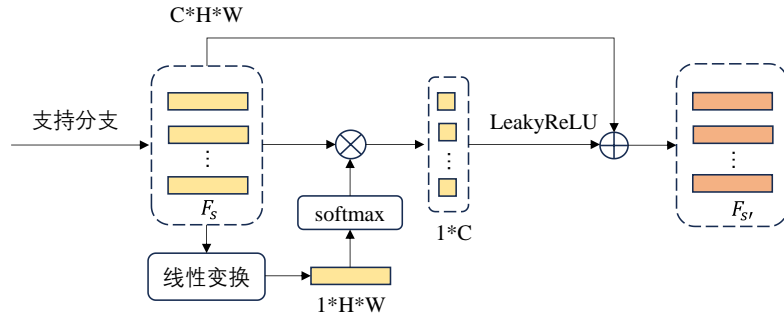


图 6 全局特征融合模块

如图 6 所示：支持分支提取到的图像特征为 $F_s \in R^{C \times H \times W}$ ，引入可学习的线性层 $L \in R^{C \times 1}$ 对特征图 F_s 做线性变换，即对每个空间位置的特征进行加权，并生成一个相应的输出 $\omega \in R^{1 \times H \times W}$ 。这个输出代表了每个空间

位置的权重。这些空间权重经过 softmax 归一化后，成为对应像素点的权重分布。通过将权重分布与支持特征在通道维度上进行矩阵乘法运算，得到全局通道特征 $G \in R^{1 \times C}$ 。以上过程用公式表示为：

$$\omega = \text{Linear}(F_S) \quad (3)$$

$$G = \text{softmax}(\omega) \otimes F_S \quad (4)$$

式中： Linear 表示执行线性变换的过程， \otimes 表示矩阵乘法运算。随后，使用 leaky ReLU 激活函数对全局通道特征 G 进行激活并叠加到原始支持特征上。

$$F_{S'} = \alpha \cdot \text{LeakyReLU}(G) \oplus F_S \quad (5)$$

式中： α 表示缩放因子，用以调节全局通道特征所占的比例，通过对原始支持特征的叠加，帮助改善 PCB 图像上缺陷类别之间的区分度。

2.5 目标函数

与 Meta R-CNN 相同，损失函数包含两个部分：

$$L = L_{rpn} + L_{reg} + L_{cls} + L_{meta} \quad (6)$$

第一部分为标准的 Faster R-CNN 损失，其中， L_{rpn} 是 RPN 的输出损失，用以区分前景和背景并细化锚框。 L_{cls} 是 Bbox 分类器的交叉熵损失。Bbox 分类器用于目标检测中边界框（bounding box）的分类任务，其主要目标是将边界框与不同目标类别进行匹配，确定该边界框的对象属于哪个目标类别，最终输出一个关于目标类别的概率预测。交叉熵损失函数通过比较目标预测概率与真实标签 one-hot 编码的交叉熵，随着预测准确度的提高，交叉熵的值逐渐减小，帮助网络学习目标分类信息。 L_{reg} 是 Bbox 回归器的 Smooth L1 损失。Bbox 回归器接收候选框的特征和位置信息，并输出修正后的边界框坐标。其目标是最小化预测框与真实框之间的差异，并通过使用 Smooth L1 损失函数进行优化。Smooth L1 损失通过在偏移量小于阈值时使用 L2 范数计算损失，在偏移量大于等于阈值时使用 L1 范数计算损失，平衡精度和训练稳定性。

第二部分为元损失，不同类别学习出的支持特征向量应当具备对不同类别的 RoI 特征有着不同的选择效果，这样可以避免预测过程中产生模糊和歧义。 L_{meta} 利用交叉熵损失实现，促使目标向量落入目标所属的类。

3 元学习训练方式

现有的小样本目标检测方法通常采用两阶段训练范式：基训练和小样本微调。设定数据集为 $D = \{(x, y), x \in X, y \in Y\}$ ，其中 x 为输入图像， y 为对应标签，该数据集共有 C 个类别，在整个小样本学习任务中将所有类别 C 划分为基类 C_b 和新类 C_n ， C_b 中的样本数量远大于 C_n ，值得说明的是： $C_b \cup C_n = C$ 并且 $C_b \cap C_n = \emptyset$ 。通常，在训练过程中利用丰富的 C_b 样本进行基类训练，然后在少量的 m-shot($m=1, 2, 3, \dots$)新类样本 C_n 上进行微调，最终目标是学习出一个可以检测新类样本 C_n 的模型。

元学习框架遵循以上通用的 FSOD 设置但有所不同，第一阶段从大量的基类样本中提取元知识这个阶段称为元训练，第二阶段利用基类和新类样本进行微调，这个阶段称为元测试。元学习通过构建元任务的方式进

行训练, 设 $S=\{(x_1, y_1), \dots, (x_m, y_m)\}_{i=1}^m$ 表示支持集, 包含 m 个不同的感兴趣目标, $Q = \{q_i\}_{i=1}^q$ 为查询集, 包含一个或多个图像和标注信息, 可以用公式将元任务表示为 $T = \{S_1, \dots, S_n, Q\}$ 。N-way M-shot 任务设置中, 在元训练阶段从基类 C_b 中随机抽取 N 个类别和 M 个带标注的实例构成 $N \times M$ 个支持集样本, 从 C_b 中抽取若干样本构成查询集。通过以元任务的形式在 PCB 缺陷检测数据集中协同训练, 模型具备在只有少量支持样本中检测出查询图像目标的能力。与具有大量样本数据的基类不同, 新类只有 M 个目标样本。

以上这种两阶段元学习任务划分方式如图 7 所示: 其中基础类别用黄色标注框进行标注, 新类别用红色框标注。在元测试阶段从基类与新类中采样相同数量的训练样本构建元学习任务。这样做的目的是在微调新类的同时避免模型在基类的性能下降。

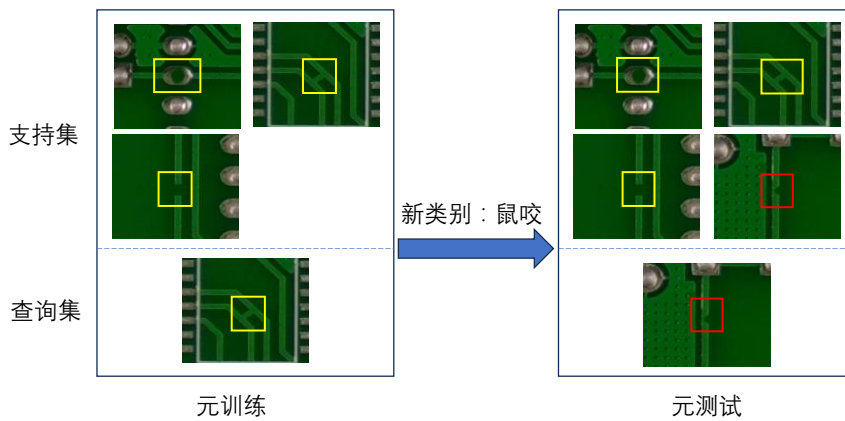


图 7 元学习任务划分

4 实验数据分析

4.1 PKU-Market-PCB 数据集

PKU-Market-PCB^[20]是一个人工合成的公开 PCB 缺陷图像数据集。适用于缺陷检测任务的有 693 张图像, 共有 2953 个标注实例, 平均像素为 2777×2138 。PCB 缺陷类别有 6 种: 缺孔 (missing_hole), 鼠咬 (mouse_bite), 开路 (open_circuit), 短路 (short), 毛刺 (spur), 假铜 (spurious_copper), 且一张缺陷图像只包含一个缺陷类别。在训练任务上随机选择 554 张图像作为训练集, 139 张图像作为验证集。在 FSOD 任务中选取其中的鼠咬 (mouse_bite) 类别作为新类, 其余五种类别作为基类。预训练阶段只用基类数据, 微调阶段加入同等实例的基类和新类数据。数据集示例如图 8 所示, PCB 缺陷目标极小, 板面线路复杂。将数据集截取放大后如图 9 所示, 黄色框标注部分为不同类别的缺陷实例, 新类别的鼠咬类与基类毛刺类和开路类之间相似性较大, 易于混淆。




图 8 PKU-Market-PCB 数据集示例

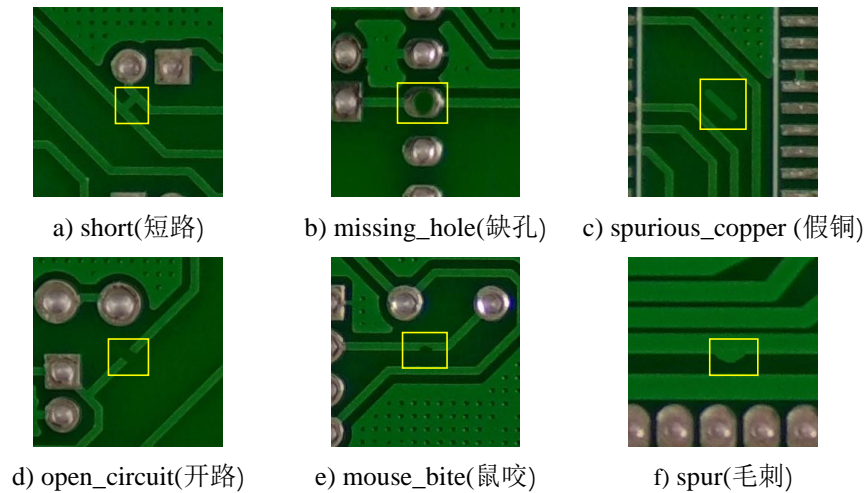


图 9 PKU-Market-PCB 数据集缺陷类别

4.2 DeepPCB 数据集

DeepPCB 数据集^[21]是由上海交通大学图像处理与模式识别研究所公开的 PCB 缺陷数据集。数据集包含 1500 张 PCB 缺陷图像，共有 6163 个标注实例，PCB 缺陷类别共有 6 种：开路（open）、残铜（copper）、针孔（pin-hole）、短路（short）、鼠咬（mousebite）和毛刺（spur）。与 PKU-Market-PCB 数据集不同，该数据集的每张缺陷图像包含若干个不同种类缺陷。同时，图像颜色为黑白色，像素为标准的 640×640。由于在 PKU-Market-PCB 数据集中选取鼠咬（mousebite）类别作为新类别，为验证算法的泛化性能，在 DeepPCB 数据集上选取毛刺（spur）类别作为新类别，其余 5 个类别作为基类，随机选取 1200 张图像为训练集，300 张图像为验证集。数据集示例如图 10、图 11 所示。




图 10 DeepPCB 数据集示例

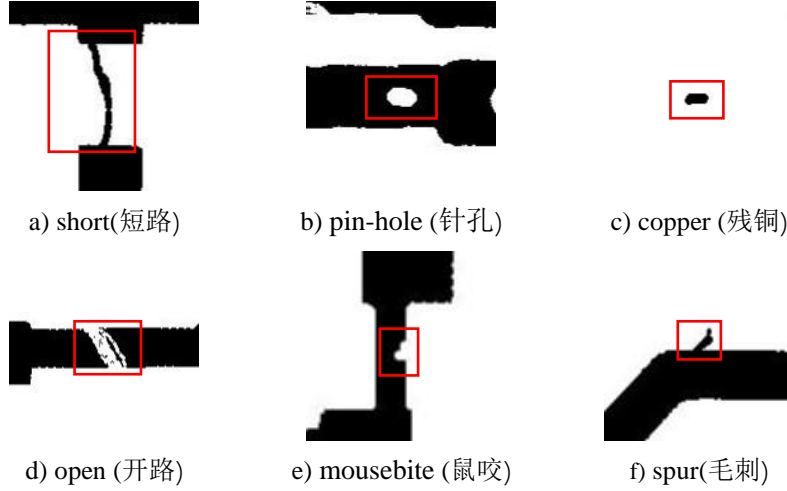


图 11 DeepPCB 数据集缺陷类别

4.3 性能评价指标

评估 PCB 缺陷检测的性能指标采用单个类别的检测精度 (Average Precision, AP) 值, AP 是通过计算 precision-recall 曲线下的面积得到的, 由公式表示:

$$\begin{aligned} Precision &= \frac{TP}{TP + FP} \\ Recall &= \frac{TP}{TP + FN} \end{aligned} \quad (7)$$

式中: TP 是将正例正确划分为正例的数量, FP 是将负例错误地划分为正例的数量, FN 是正例被错误划分为负例的数量。 TP 和 FP 通过同类的预测框与真实框的交并比 IoU 来确定, 若 IoU 大于一定阈值, 则该检测框为 TP , 否则为 FP , 如果在图像上没有检测到对应目标, 则被标记为 FN 。 IoU 公式定义:

$$IoU = \frac{area(B_p \cap B_{gt})}{area(B_p \cup B_{gt})} \quad (8)$$

式中: B_p 为预测框, B_{gt} 为真实标注框。 $area()$ 表示面积。 IoU 通过计算 B_p 与 B_{gt} 之间的交并比表示预测框对真实框的重合程度。参照 Pascal VOC 的准则, 本次实验中 IoU 的阈值取 0.5, 以此计算对应的 AP 值。

4.4 实验设置

本文中的所有方法均是在 Mmdetection 上进行实现, 使用 pytorch 框架, 4 块 RTX3090 GPU 进行训练。为进行公平比较, 所有模型均采用多尺度训练方式。骨干网络采用 ImageNet^[22]上预训练的 ResNet101。训练过程中将 SGD 作为优化器, 单个 GPU 的批大小为 4。全局特征融合模块常数 α 设为 0.1。元训练阶段, 设置学习率为 0.02, 动量为 0.9, 权重衰减为 $1e4$, 最大迭代次数为 8000。元测试阶段, 学习率设为 0.02。将基类与新类设置相同的样本数并在 $K=\{1,2,3,5,10\}$ shots 对应 $\{100,100,200,500,600\}$ 迭代次数, 保持其他超参数与 Meta R-CNN 相同。

4.5 消融实验

基于所提出的方法设计了消融实验, 分析了系统中各个模块的有效性。所有消融实验均在

PKU-Market-PCB 数据集上进行, 展示新类(鼠咬)的检测性能, 指标为 AP(%)。

在 Meta R-CNN 的基础上调整训练策略, 具体地, 在元测试阶段冻结骨干网络和 RPN 网络, 仅微调头部, 尽量保证基类向新类知识的泛化过程中分类准确性不受影响。由表 1 可知, 在元测试阶段的调整使得基线网络总体精度显著提升, 尤其是在 10-shot 上增长较为明显, 这表明了元学习结合微调策略的有效性。同时, 改进后的基线网络更加节省显存, 因为在元测试阶段不需要重新训练整个网络。

表 1 基线网络改进效果


shot	Meta R-CNN ^[13]	基线网络
1	17.3	20.1
2	18.6	21.9
3	29.0	35.1
5	34.9	40.6
10	40.7	47.4

表 2 分别对自注意力模块和全局特征融合模块进行验证, 用以分析元特征增强方法的对模型的有效性。可以直观看出两个模块在效果上是互相独立的, 能够共同促进新类检测效果的提升。在 10-shot 任务中, 改进后的模型较基线网络提升了 15% 的新类精度, 而在 1-shot 任务中, 提升了约 23% 的精度值。说明在极端样本条件下, 元特征增强算法显著提升了模型的泛化性能, 下面将对各个模块进行分析。

表 2 元特征增强模块的有效性验证

Shot	全局特征融合	自注意力	全局特征融合+自注意力
1	24.7	40.6	43.0
2	31.4	43.9	51.7
3	48.6	44.1	54.4
5	52.3	55.4	61.7
10	60.1	58.0	62.4

1) 全局特征融合模块的改进。在 1-shot 任务中, 模块的改进效果不是非常明显, 因为训练样本数太少, 模型学习到的全局特征不够准确。而当训练样本数为 10-shot 时, 模型学习的任务特征和一些细节信息越来越充分。此时, 引入全局特征融合模块帮助模型学习到高层次的语义信息用以区分不同类别缺陷。如图 12 所示, 在 10-shot 任务中, 使用相同 0.3 阈值条件下检测新类别时, a)图在支持分支进行特征融合, b)图表示使用基线网络原始特征。黄色框显示了检测框的位置以及置信度。显然, 两者在定位效果上没有太大的区别, 但是使用原始支持特征在新类别上的置信度较低, 分类产生了歧义, 而在通道维度上对支持特征进行融合后, 分类效果显著增强, 同时也进一步说明支持特征对于类别区分的重要性。



a)全局特征融合效果

b)原始特征效果

图 12 全局特征融合模块对比效果图

2) 自注意力模块的影响。与全局特征融合模块不同,在样本数较少时,自注意力模块带来显著的精度提升。随着样本数的增加,精度的提升幅度逐渐减小。这可能是由 PCB 图像特性决定的。在样本及其稀缺时,如 1-shot 或 2-shot,模型对小目标缺陷信息的捕捉能力较弱,引入自注意力模块帮助模型更加关注图像区域的细节信息,从而提高缺陷目标的召回率和精度。图 13 展示了自注意力模块对目标召回率的改善效果。在 1-10 个样本的情况下,召回率显著提升,尤其是当样本数量非常有限时,改善效果更加明显。


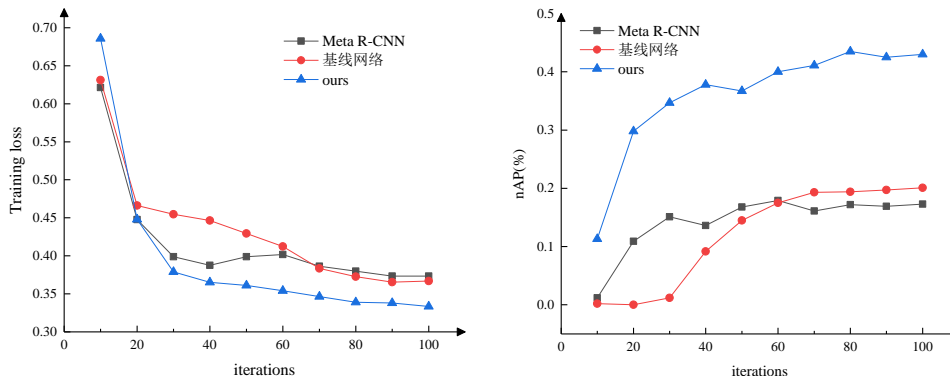


图 13 自注意力模块召回率对比

为更清晰的观察改进网络的影响,对 Meta R-CNN 算法、基线网络以及本文算法在 1-shot 和 10-shot 任务中的损失变化曲线(图 14a 和 14c)以及新类检测精度(AP on the novel class, nAP)变化曲线(图 14b 和 14d)进行分析。在 1-shot 任务中,随着迭代次数的增加,所有模型的损失值均呈现下降趋势,其中本文模型展现出较快的收敛速度,表明其能够迅速适应新的检测场景。在每隔 10 个迭代次数的精度验证中,基线网络在迭代 60 次后的 nAP 值超过了 Meta R-CNN,并逐步稳定下来。

在 10-shot 任务中,当迭代次数达到 500 次时,各模型均趋于收敛。尽管 Meta R-CNN 的损失值相对较低,但其在新型缺陷检测场景的验证精度低于其他两种算法,这表明其在适应新类别方面的不足,并存在一定的过拟合风险。此外,尽管模型的损失值持续降低,但新类别的验证精度仍然表现出一定的波动,这可能是在构建元学习任务时,支持样本和查询样本的分布具有随机性和不确定性,导致模型在训练过程中难以稳定学习到泛化的参数。综上所述,本文算法在小样本 PCB 缺陷检测任务中,无论在新场景的适应能力还是在检测精度方面,都表现出更为优越的性能,充分证明改进策略的有效性。



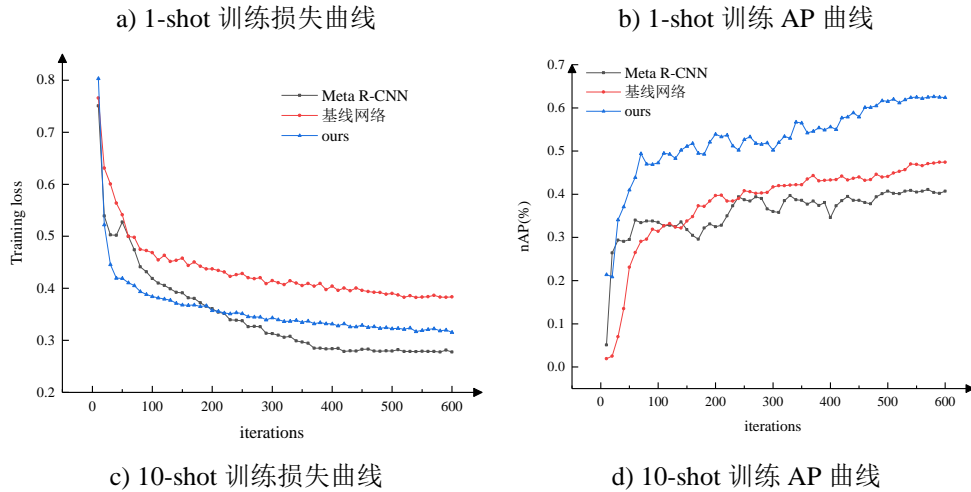


图 14 模型训练过程分析

4.6 与其他方法对比

基于深度学习的通用目标检测需要大量标注样本进行训练。然而，当可用的带有标注的样本数量有限，训练集与测试集之间存在分布差异时，检测效果会显著下降。表 3 展示了通用目标检测模型 Faster-RCNN^[18]、YOLOV8、RT-DETR^[23]与本文方法在两个 PCB 缺陷检测数据集上的对比情况，指标为 AP (%)。其中，通用检测算法在 30shot 时相较于 10shot 精度提升明显。然而，由于样本数量的限制，导致其检测精度非常不理想。包含 30 个标注样本的情况下，通用目标检测算法新类别 AP 值最高只能达到 39.0%，在性能上与本文提出的算法差距较大。因此，需要从模型和算法等多方面挖掘少量样本中蕴含的先验知识，以提升目标检测效果。

表 3 与传统目标检测方法的对比

	Class	Shot	Faster-RCNN ^[18]	YOLOV8	RT-DETR ^[23]	Ours
PKU-Market-PCB	mouse_bite	5	—	—	—	61.7
		10	4.6	10.3	12.7	62.4
		30	13.6	37.4	28.2	64.3
DeepPCB	spur	5	—	—	—	60.5
		10	6.1	11.6	13.4	66.4
		30	14.9	38.2	39.0	71.2

当前 FSOD 算法在自然图像的检测任务中表现较好，但未充分考虑 PCB 缺陷类间相似性大、目标尺度较小等特性带来的问题。在分类上，本文算法借鉴了 TFA^[9]微调策略，尽量保证基类向新类知识迁移过程中类别区分不受影响。同时，全局特征融合模块帮助支持分支学习到更加丰富的语义信息，减少分类偏见。此外，Meta R-CNN，VFA^[14]等模型直接采用原始骨干网络提取的特征，可能会导致大量的微小缺陷特征信息丢失。而本文引入的自注意力模块提高了模型对于小目标缺陷信息的捕捉能力，较好地解决这个问题。


在相同的实验环境下，采用 Meta R-CNN^[12]、TFA^[9]、MPSR^[11]、VFA^[14]四种小样本目标检测算法与本文方法进行对比，并分别在 PKU-Market-PCB 的鼠咬类别和 DeepPCB 的毛刺类别中进行测试。根据表 4 的实验结果，即使在不同的数据集和缺陷类别下，该模型相较其他 FSOD 模型仍然表现出优异的检测效果。尤其在 1shot、2shot、3shot 等极端样本条件下，该模型具有明显的优势。因为训练样本数量太少，导致其他 FSOD 模

型无法充分学习到缺陷特征信息，进而在新的缺陷场景上的泛化能力不足。此外，随着训练样本数量的增加，模型能够获取的先验知识也会增多，因此所有 FSOD 算法的精度都会同步上升。

表 4 与小样本目标检测方法的对比

Class		Shot	Meta R-CNN ^[12]	TFA ^[9]	MPSR ^[11]	VFA ^[14]	Ours
PKU-Market-PCB	mouse_bite	1	17.3	16.3	17.2	31.1	43.0
		2	18.6	25.6	26.2	32.1	51.7
		3	29.0	30.2	24.6	41.4	54.4
		5	34.9	46.7	48.2	50.9	61.7
		10	40.7	50.9	54.3	56.4	62.4
DeepPCB	spur	1	21.0	22.1	21.5	42.6	52.1
		2	24.9	24.6	34.8	43.0	53.5
		3	35.1	39.9	45.3	47.0	60.5
		5	49.2	51.6	50.0	58.3	61.1
		10	49.8	52.2	59.4	61.2	66.4

图 15 列举了各模型元训练与微调阶段的精度对比，元训练 mAP 表示在初始元训练阶段 5 个基类别的平均精度值，bAP（AP on the base class）与 nAP（AP on the novel class）分别表示微调阶段基类与新类的检测精度值。在元训练阶段，本文模型的精度仅次于 MPSR，并且相较于 Meta R-CNN 实现了约 2% 的精度提升。在 1-shot 任务中，各模型 nAP 相较于 bAP 存在明显差距，表明在极少量样本的条件下，模型在新的检测任务上的学习效果非常不理想。而当样本数量为 10 个时，nAP 与 bAP 之间的差距显著缩小，说明增加样本数量能够有效提高模型对新类别的适应能力。此外，即使基类的样本数量有限，通过微调后的基类精度仍然能够达到甚至超过使用大量样本进行元训练的基类精度，表示小样本微调在一定程度上可以提升模型基类检测性能。通常情况下，元训练阶段的精度与微调阶段的精度呈正相关。然而，尽管 MPSR 模型在基类训练阶段展现出最高的精度，其小样本新类的检测精度却未能达到预期，说明需要从微调策略和具体对象等多个方面提升模型的新场景适应能力。






图 15 各模型基类与新类精度对比分析

取 PKU-Market-PCB 数据集 10-shot 任务下部分图像检测结果可视化如图 16 所示, Meta R-CNN 算法倾向于将新类错误地识别为基类, 导致类别之间的混淆较为明显。本节算法显著改善了新类缺陷的误检问题, 并且保持较高的置信度。此外, 目标的漏检率也得到了一定程度的降低。




图 16 新类别可视化对比图

5 结束语

本文针对小样本条件下 PCB 缺陷检测, 提出了一种基于元特征增强的 FSOD 方法。通过将微调策略与元学习方案相结合, 在元训练阶段仅微调头部, 改善分类准确性。对于 PCB 图像缺陷检测任务中实例目标较小的特点, 在查询分支骨干网络部位嵌入自注意力模块, 提高对 PCB 表面小尺寸缺陷的关注度, 显著提升了目标召回率。针对在检测过程中基类与新类别易于混淆的现象, 在支持分支上添加了全局特征融合模块, 改善了 PCB 表面缺陷检测任务中小样本数据集类别样本不均衡的情况。本文方法在极端小样本条件下效果明显, 在新类别的检测精度显著高于大部分 FSOD 模型。下一步将在保证模型高检测精度的前提下, 提升模型的检测速度以及召回率, 使之更适于实际应用。

参考文献:

- [1] WU Yiquan, ZHAO Langyue, YUAN Yubin, et al. Research status and the prospect of PCB defect detection algorithm based on machine vision[J]. Chinese Journal of Scientific Instrument, 2022, 43(08): 1-17 (in Chinese). [吴一全, 赵朗月, 苑玉彬, 杨洁. 基于机器视觉的 PCB 缺陷检测算法研究现状及展望[J]. 仪器仪表学报, 2022, 43(08): 1-17.]

- [2] HE Y, SONG K C, MENG Q G, et al. An end-to-end steel surface defect detection approach via fusing multiple hierarchical features[J]. IEEE transactions on instrumentation and measurement, 2019, 69(4): 1493-1504.
- [3] LUO J X, YANG Z Y, Li S P, et al. FPCB surface defect detection: A decoupled two-stage object detection framework[J]. IEEE Transactions on Instrumentation and Measurement, 2021, 70: 1-11.
- [4] LIAO Xinting, ZHANG Jie, LV Shengping. Defect detection for PCB by combining shallow features and attention mechanism[J/OL]. Computer Integrated Manufacturing Systems: 1-17(in Chinese). [廖鑫婷,张洁,吕盛坪.融合浅层特征和注意力机制的 PCB 缺陷检测方法[J/OL]. 计算机集成制造系统:1-17.]
- [5] LIN Q Q, ZHOU J Z, MA Q R, et al. EMRA-Net: A pixel-wise network fusing local and global features for tiny and low-contrast surface defect detection[J]. IEEE Transactions on Instrumentation and Measurement, 2022, 71: 1-14.
- [6] LI Jian, LI Hua, HU Xiangkun, et al. Research progress of surface defect detection technology based on deep learning[J]. Computer Integrated Manufacturing Systems: 1-20 (in Chinese) . [李健,李华,胡翔坤,等.基于深度学习的表面缺陷检测技术研究进展[J].计算机集成制造系统, 1-20.]
- [7] ZHANG Zhenwei, HAO Jianguo, HUANG Jian, et al. Review of few-shot object detection[J]. Computer Engineering and Applications ,2022,58(5):1-11(in Chinese). [张振伟,郝建国,黄健,等.小样本图像目标检测研究综述[J].计算机工程与应用, 2022, 58(5):1-11.]
- [8] LI Hongguang, WANG Yufeng, YANG Lichun. Meta-learning-based few-shot object detection for remote sensing images [J/OL]. Journal of Beijing University of Aeronautics and Astronautics,2022:1-16(in Chinese). [李红光,王玉峰,杨丽春. 基于元学习的小样本遥感图像目标检测[J/OL].北京航空航天大学学报,2022:1-16.]
- [9] WANG X, HUANG T, GONZALEZ J, et al. Frustratingly simple few-shot object detection[C]//Proceedings of the 37th International Conference on Machine Learning,2020:9919-9928.
- [10] SUN B, LI B, CAI S, et al. Fscf: Few-shot object detection via contrastive proposal encoding[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 7352-7362.
- [11] WU J, LIU S, HUANG D, et al. Multi-scale positive sample refinement for few-shot object detection[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XVI 16. Springer International Publishing, 2020: 456-472.
- [12] YAN X P, CHEN Z L, XUA, et al. Meta r-cnn: Towards general solver for instance-level low-shot learning[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 9577-9586.
- [13] ZHANG G J, LUO Z P, CUI K W, et al. Meta-DETR: Image-level few-shot detection with inter-class correlation exploitation[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2022.
- [14] HAN J M, REN Y Q, DING J, et al. Few-shot object detection via variational feature aggregation[J]. arXiv preprint arXiv:2301.13411, 2023.
- [15] SIMONYAN K, ZISSERMAN A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
- [16] SANDLER M, HOWARD A, ZHU M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
- [17] HE K M, ZHANG X Y, REN S Q, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
- [18] REN S Q, HE K M, GIRSHICK R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
- [19] SUBAKAN C, RAVANELLI M, CORNELL S, et al. Attention is all you need in speech separation[C]//ICASSP 2021-2021 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2021: 21-25.
- [20] HUANG W B, WEI P. A PCB dataset for defects detection and classification [J]. Journal of Latex Class Files, 2018, 14(8): 1-9.
- [21] TANG S, HE F, HUANG X, et al. Online PCB defect detector on a new PCB defect dataset. arXiv 2019[J]. arXiv preprint arXiv:1902.06197.

[22] DENG J, DONG W, SOCHER R, et al. Imagenet: A large-scale hierarchical image database[C]//2009 IEEE conference on computer vision and pattern recognition. Ieee, 2009: 248-255.

[23] LV W Y, ZHAO Y, XU S L, et al. Dets beat yolos on real-time object detection[J]. arXiv preprint arXiv:2304.08069, 2023.

作者简介:

+宋 涛(1987-), 男, 湖北人, 副教授, 博士, 研究方向: 图像处理、计算机视觉等, 通讯作者, E-mail: tsong@cqut.edu.cn;

李 程(1995-), 男, 河南许昌人, 硕士研究生, 研究方向: 计算机视觉, 智能制造, E-mail: 760608033@qq.com;

熊海龙(1996-), 男, 重庆云阳人, 硕士研究生, 研究方向: 工业大数据, E-mail: 378035095@qq.com;

叶定兴(1999-), 男, 重庆涪陵人, 硕士研究生, 研究方向: 机器视觉, E-mail: 2567407957@qq.com;

袁 川(2000-), 男, 四川巴中人, 硕士研究生, 研究方向: 智能感知, E-mail: 563573959@qq.com;

赵月雯(2000-), 女, 贵州遵义人, 硕士研究生, 研究方向: 计算机视觉, E-mail: 1594200622@qq.com;

唐宏耀(1998-), 男, 四川资阳人, 硕士研究生, 研究方向: 三维重建, E-mail: tw1998mike000@163.com;

冉 璐(1997-), 女, 重庆南川人, 硕士研究生, 研究方向: 计算机视觉, E-mail: kyrann@163.com